

Introduction aux architectures micro services

Cours Architectures distribuées
Alexandre Touret

Alexandre Touret

Architecte logiciel à Worldline

 <https://blog.touret.info>

 <https://github.com/alexandre-touret/>

 <https://www.linkedin.com/in/atouret/>

Introduction

Ce cours vise à introduire les concepts fondamentaux des architectures microservices.

Les points abordés seront:

- Fondamentaux (Pourquoi? Les défis, comment les concevoir)
- Protocoles (HTTP, REST, GRAPHQL, GRPC)
- Couplage lâche
- Cohérence des données, transactions distribuées et utilisation de messageries asynchrones
- Monitoring & Observabilité (Optionnel)
- Sécurité (Optionnel)

Fondamentaux

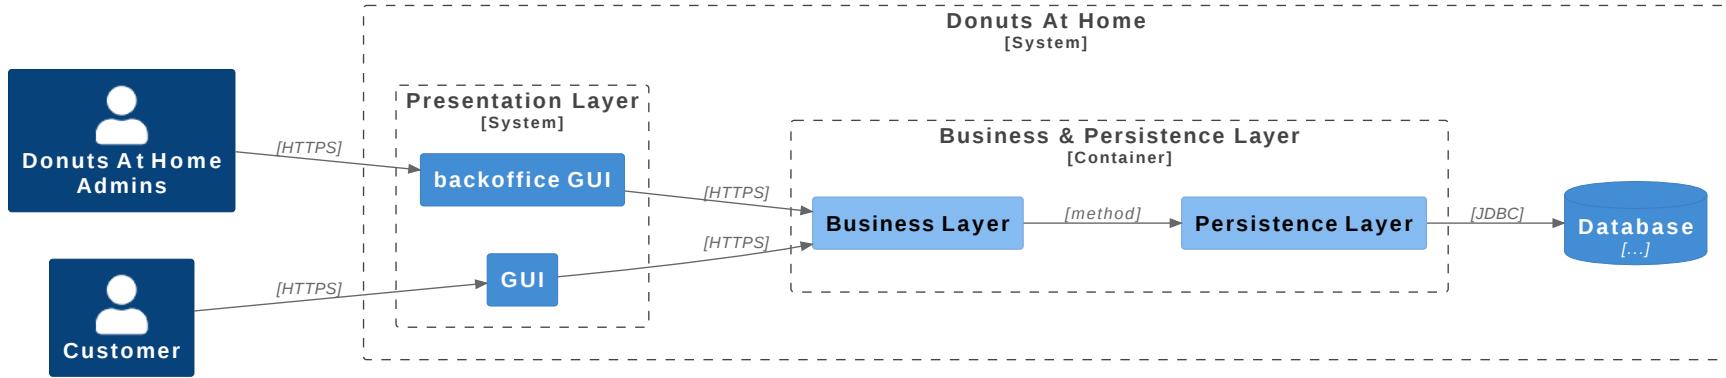
Définition d' Amazon

Microservices are an architectural and organizational approach to software development where software is composed of small independent services that communicate over well-defined APIs. These services are owned by small, self-contained teams.

Microservices architectures make applications easier to scale and faster to develop, enabling innovation and accelerating time-to-market for new features.

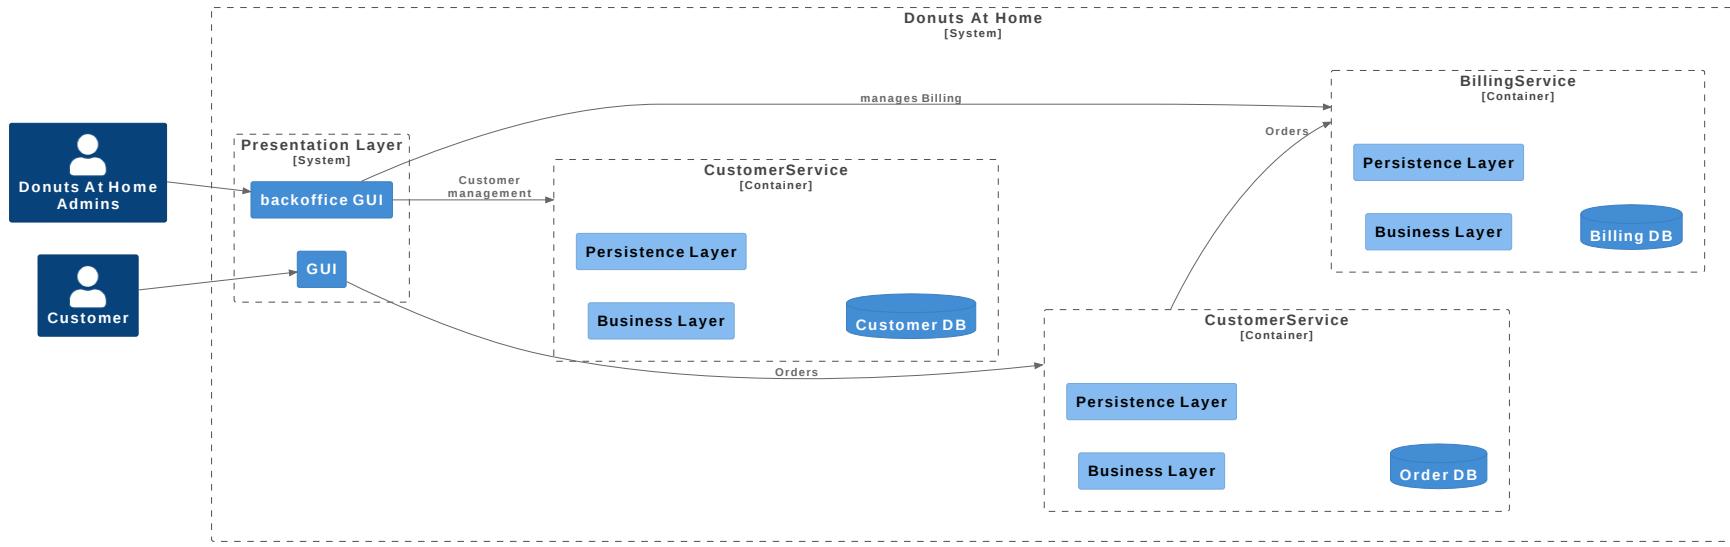
Monolithe vs Microservices

Un monolithe



Tous les composants sont déployés dans le même livrable et sur la même machine.

Une plateforme microservices



Chaque domaine fonctionnel est déployé indépendamment.

Pourquoi ?

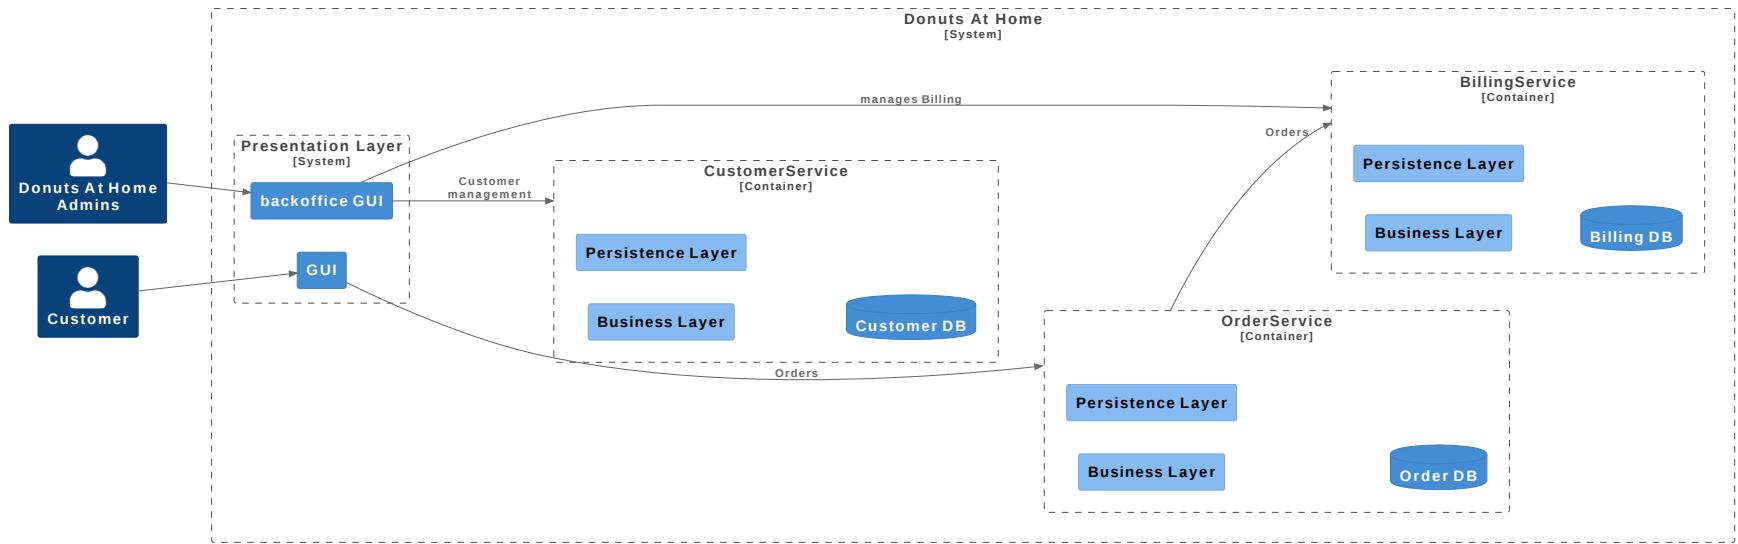
- Donner plus d'autonomie aux équipes en charge d'un microservice
- Faciliter la gestion du changement par des déploiements plus unitaires et modules (c.-à-d. plus petits)
- Favoriser l'innovation
- Utiliser la technologie la plus appropriée pour chaque service
- Améliorer et cibler la scalabilité

Principes de base

Chaque microservice est composé d'une API et une base de données ou tout autre moyen de stockage (si nécessaire).

Il est développé et opéré par une "*Pizza Team*" qui fait tout du dev à la prod

Les fonctionnalités ne sont accessibles que par le biais des API --> On n'accède pas directement à la base de données.



Protocoles

Il y a deux types de flux utilisés dans les connexions entre services :

- Synchrones: Utilisation de protocoles basés sur HTTP ou GRPC
- Asynchrones: Utilisation de messageries asynchrones ou streaming de données

Transactions synchrones

Deux grandes familles de protocole sont utilisées dans les transactions synchrones

Fonctionnalité	gRPC	API HTTP avec JSON
Contrat	Obligatoire (.proto)	Facultatif (OpenAPI)
Protocole	HTTP/2	HTTP
Payload	Protobuf (petit, binaire)	JSON (grand, lisible par l'homme)
Diffusion en continu	Client, serveur, bidirectionnel	Client, serveur
Prise en charge des navigateurs	Non (nécessite grpc-web)	Oui
Sécurité	Transport (TLS)	Transport (TLS)
Génération de code client	Oui	OpenAPI + outils tiers

API HTTP

Les API basées sur HTTP utilisent soit GraphQL ou REST (majoritaire).

Les API REST

Les API REST (Representational State Transfer) sont un style architectural pour la conception de services web. Elles utilisent les protocoles et les standards du web, principalement HTTP, pour permettre la communication entre un client et un serveur.

Voici quelques points clés concernant les API REST :

1. Ressources (ex. `/users/{userId}`)

2. Verbes HTTP:

- `GET` : Récupérer une ressource ou une collection de ressources. (ex. `/users/1`)
- `POST` : Créer une nouvelle ressource. (ex. Envoi d'un formulaire à la ressource `/users`)
- `PUT` : Mettre à jour une ressource existante.
- `DELETE` : Supprimer une ressource.
- `PATCH` : Mettre à jour une partie d'une ressource existante

3. Sans état (stateless)

4. Possibilité de mettre en cache les requêtes

5. Représentation (ex. JSON)

6. Interface uniforme

7. Scalabilité et performance

HATEOAS

HATEOAS (Hypermedia As The Engine Of Application State) est une contrainte de l'architecture REST selon laquelle un client interagit avec une application entièrement par le biais de ressources dynamiques fournies par le serveur. Ces ressources contiennent des liens hypermedia qui indiquent les actions possibles et les transitions d'état.

Caractéristiques de HATEOAS

1. Auto-découverte
2. Navigation par liens
3. Dynamisme

Exemple

Voici une API pour une boutique en ligne. Une réponse pour obtenir les détails d'un produit pourrait ressembler à ceci en utilisant JSON :

```
{
  "id": 123,
  "name": "Chaussures de course",
  "price": 50,
  "links": [
    {
      "rel": "self",
      "href": "http://api.boutique.com/products/123"
    },
    {
      "rel": "add-to-cart",
      "href": "http://api.boutique.com/cart/add/123"
    },
    {
      "rel": "reviews",
      "href": "http://api.boutique.com/products/123/reviews"
    }
  ]
}
```

Modèle de maturité de Richardson

Ce modèle évalue la maturité d'une API REST en quatre niveaux (0 à 3), chacun ajoutant des caractéristiques supplémentaires qui rapprochent l'API des principes RESTful.

- 1. Niveau 0 : Appels à distance uniques** Exemple :
Une API avec une seule URL qui accepte différentes actions via des paramètres.

- 2. Niveau 1 : Utilisation des ressources** Exemple :

- GET /users/getUser?id=123
- POST /users/createUser

- 3. Niveau 2 : Verbes HTTP** Exemple :

- GET /users/123 (récupérer les détails de l'utilisateur avec l'ID 123)
- POST /users (créer un nouvel utilisateur)

4. Niveau 3 : Hypermedia Controls

À ce niveau, l'API intègre des hyperliens dans les réponses pour guider les clients sur les actions possibles.

Exemple de réponse HATEOAS

```
{  
  "id": 123,  
  "name": "Jane Doe",  
  "links": [  
    {  
      "rel": "self",  
      "href": "/users/123"  
    },  
    {  
      "rel": "friends",  
      "href": "/users/123/friends"  
    },  
    {  
      "rel": "update",  
      "href": "/users/123"  
    }  
  ]  
}
```

GraphQL

GraphQL est un langage de requête pour les API. Il a été développé par Facebook en 2012 et open-source en 2015.

GraphQL permet aux clients de demander précisément les données dont ils ont besoin, et rien de plus

Principes

1. Langage de requête

- GraphQL permet aux clients de définir la structure des réponses qu'ils souhaitent recevoir.
- Les requêtes GraphQL sont envoyées au serveur et le serveur retourne uniquement les données demandées.

2. Schéma fortement typé

3. Récupération de l'équivalent de plusieurs ressources en une seule requête

Exemple de requête

```
{  
  user(id: "1") {  
    id  
    name  
    friends {  
      id  
      name  
    }  
  }  
}
```

Exemple de réponse

```
{  
  "data": {  
    "user": {  
      "id": "1",  
      "name": "Alice",  
      "friends": [  
        {  
          "id": "2",  
          "name": "Bob"  
        },  
        {  
          "id": "3",  
          "name": "Charlie"  
        }  
      ]  
    }  
  }  
}
```

En résumé

Technologie	Avantages	Inconvénients
REST	Simplicité de mise en oeuvre , Stateless, interopérabilité, utilisation des standards du Web	Manque de flexibilité dans les requêtes, gestion des versions, évolutivité, surcharge réseau
GrahQL	Flexibilité, efficacité, évolutivité, documentation automatique	Pas de cache possible, tout passe par une requête POST, complexité de mise en oeuvre

Couplage lâche

Le couplage fait référence au degré d'interdépendance entre les différents modules, composants ou classes d'un système logiciel. Un couplage fort signifie que les modules sont fortement interconnectés et dépendent étroitement les uns des autres, tandis qu'un couplage faible indique une interdépendance minimale entre les modules. Le couplage est une mesure importante de la qualité du design logiciel, car un couplage fort peut rendre le système difficile à maintenir, à modifier et à tester. En revanche, un couplage faible favorise la modularité, la réutilisabilité et la maintenabilité du code.

Qu'est-ce qui crée du couplage dans les architectures microservices ?

Couplage comportemental

- Description : Se produit lorsque des services partagent des responsabilités dans les processus métier.
- Conséquence : Si un service nécessite l'aide directe d'un autre pour accomplir ses tâches, cela indique que les périmètres des services n'ont pas été correctement définis.

Couplage des connaissances

- Description : Se produit lorsque les services connaissent trop bien les implémentations internes des autres.

Couplage des schémas

- Description : Se produit lorsque les services sont liés à un ensemble commun d'interfaces ou de schémas.

Couplage temporel

- Description : Se produit lorsqu'un service attend une réponse immédiate d'un autre avant de pouvoir continuer.

Couplage des processus

- Description : Se produit lorsque les services commencent à assumer trop de responsabilités distinctes.
- Conséquence : Donne lieu à des implémentations de services difficiles à mettre à l'échelle ou à modifier.

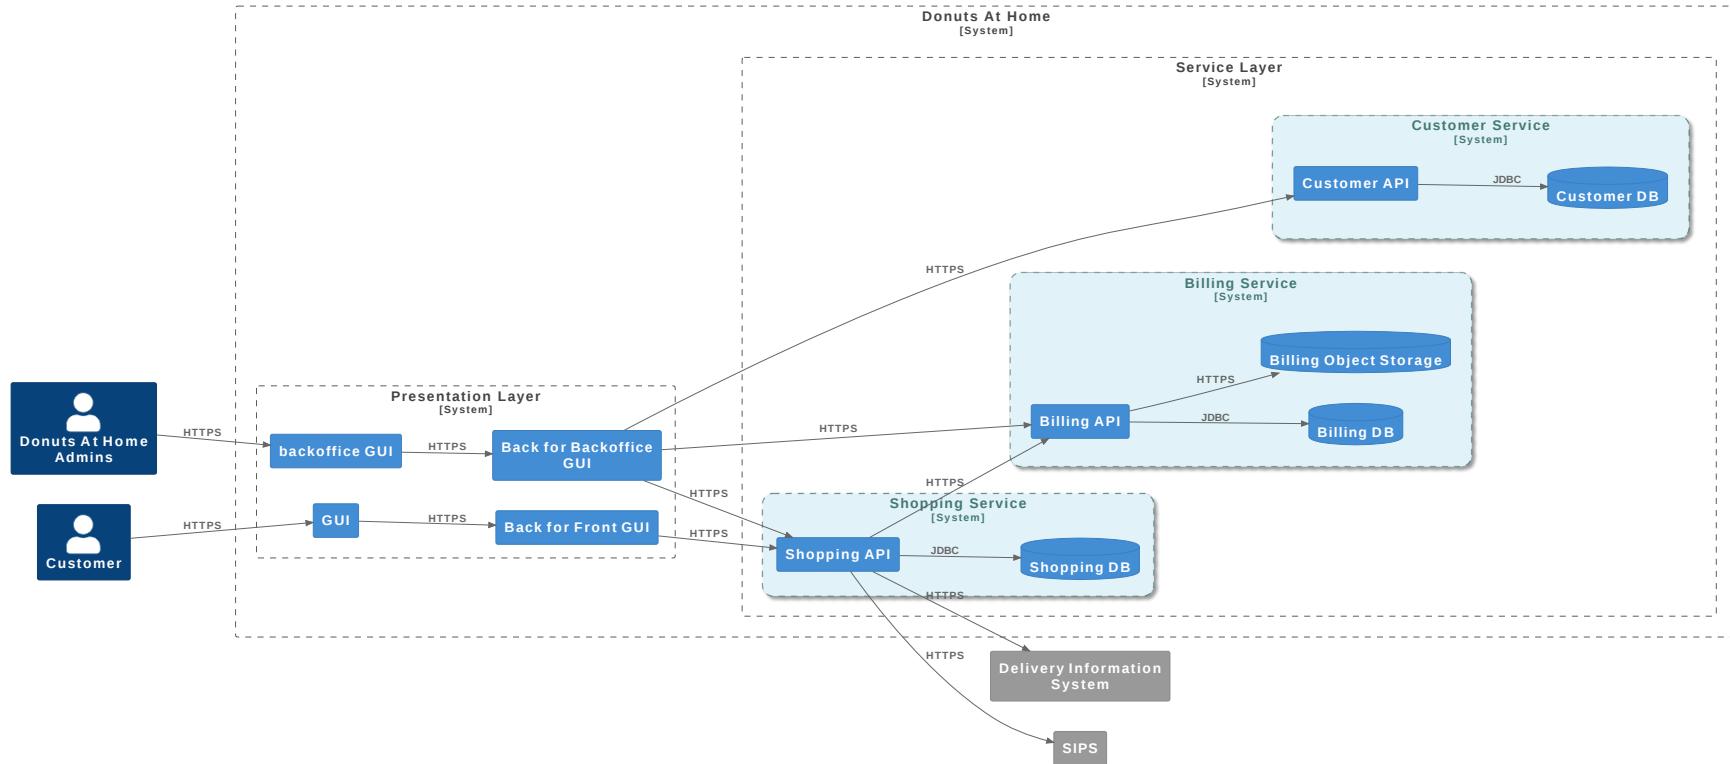
Couplage d'implémentation

- Description : Se produit lorsque les services partagent des détails d'implémentation plutôt que des contrats ou des schémas.
- Conséquence : Les API qui laissent échapper des détails d'implémentation.

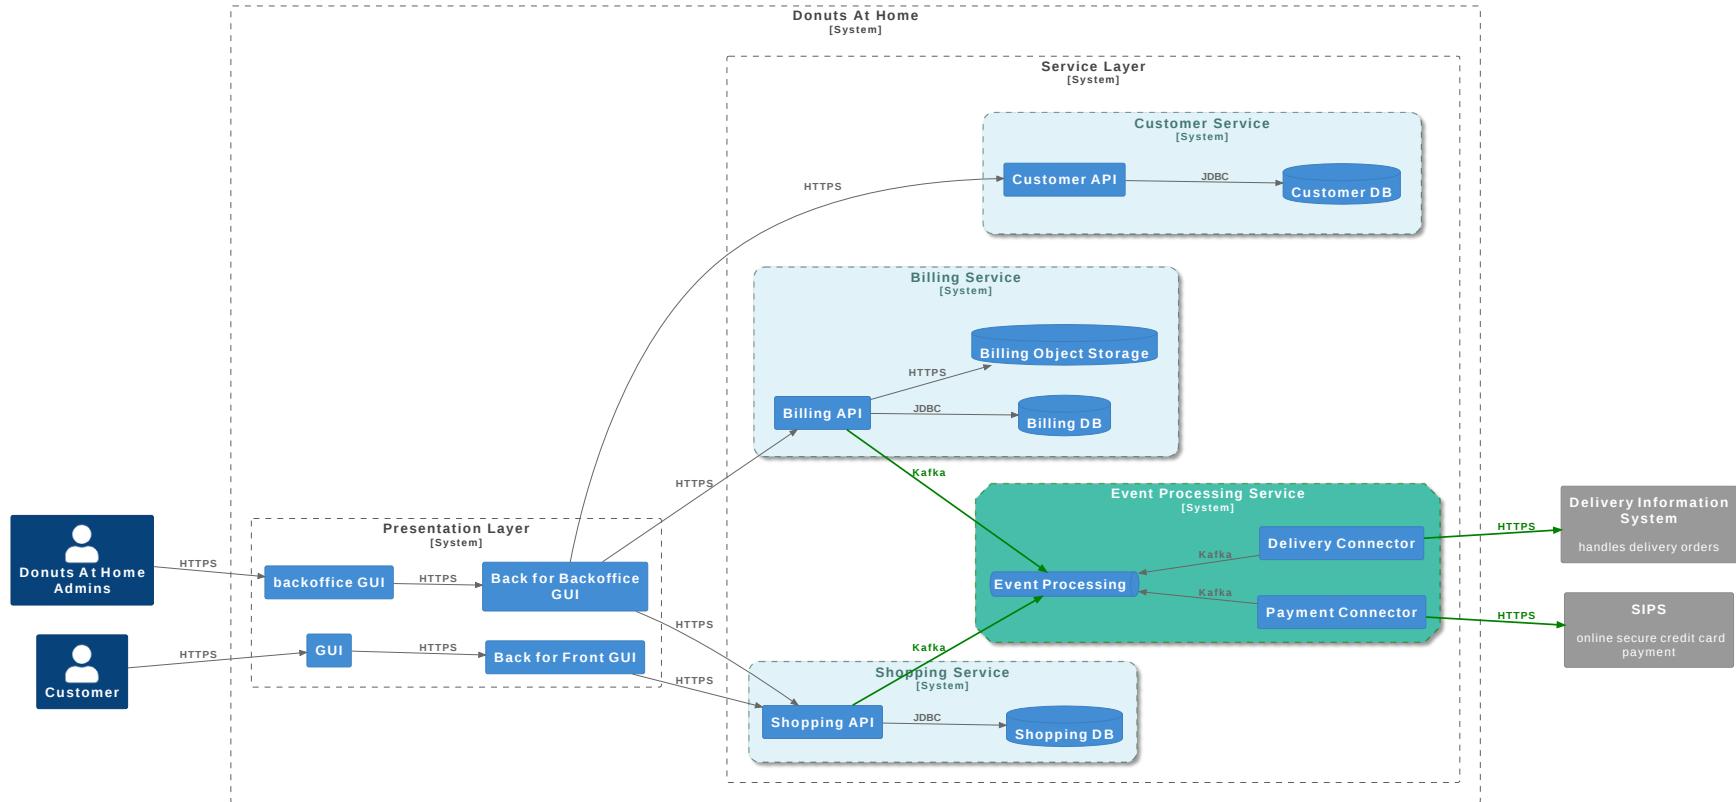
Couplage basé sur la localisation :

- Description : Se produit lorsqu'un service s'attend à ce qu'une ressource existe à un emplacement spécifique.

Exemple de couplage fort



Comment découpler les appels externes ?



Communication inter services

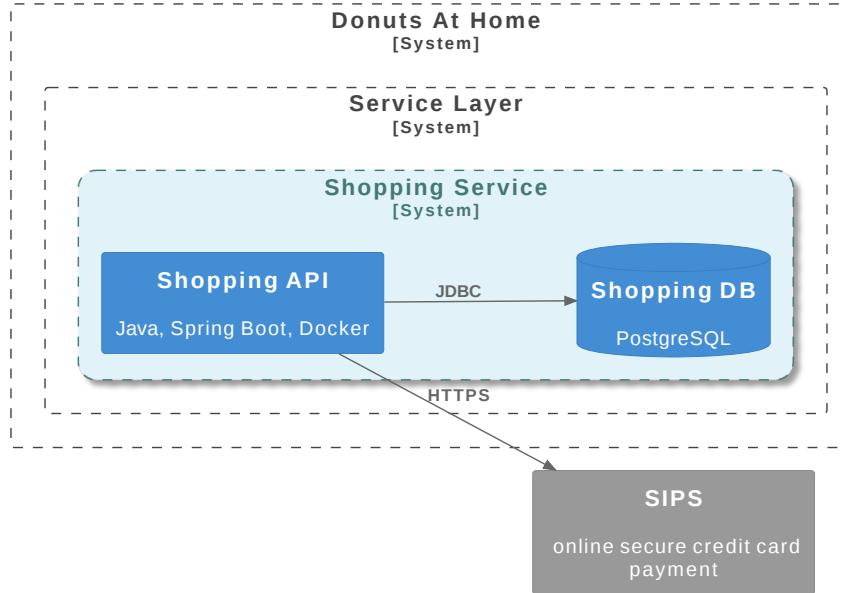
Les architectures microservices offrent leur capacité à décomposer les applications en services indépendants et faiblement couplés. La communication entre les services est cruciale pour le fonctionnement harmonieux de l'ensemble du système.

Deux approches principales existent pour orchestrer cette communication : les messageries synchrones (API) et asynchrones.

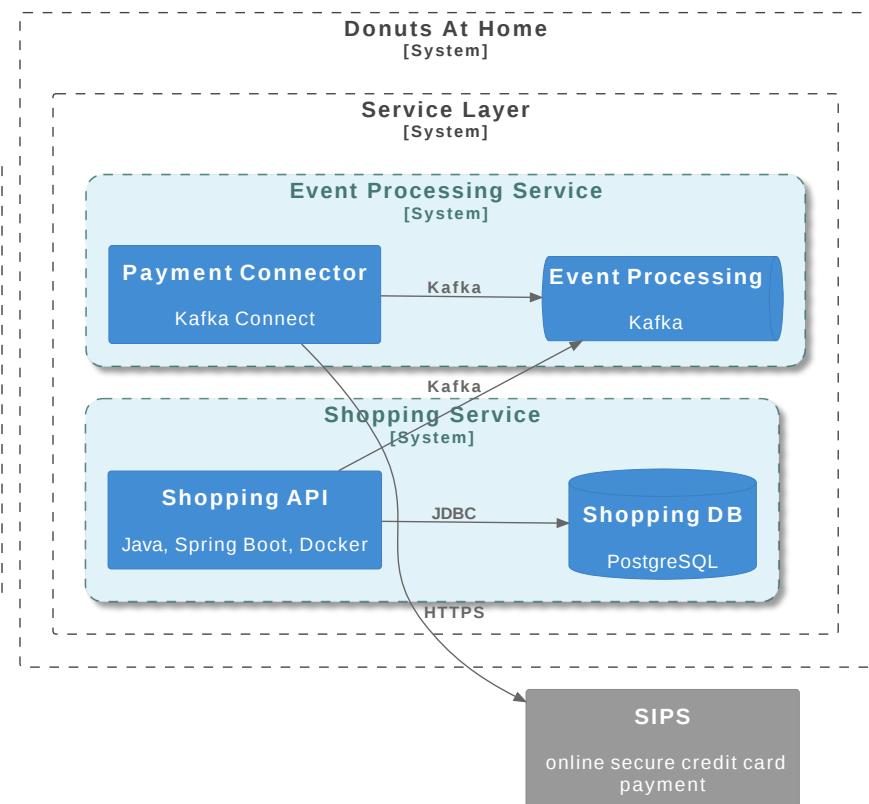
Ces dernières améliorent la résilience, la scalabilité et la flexibilité des architectures microservices.

Qu'est-ce qu'une messagerie asynchrone ?

Transaction synchrone



Transaction asynchrone



Pourquoi les utiliser ?

- Les ressources sont libérées plus rapidement
- Résilience accrue
- Scalabilité
- Faible Couplage

Composants

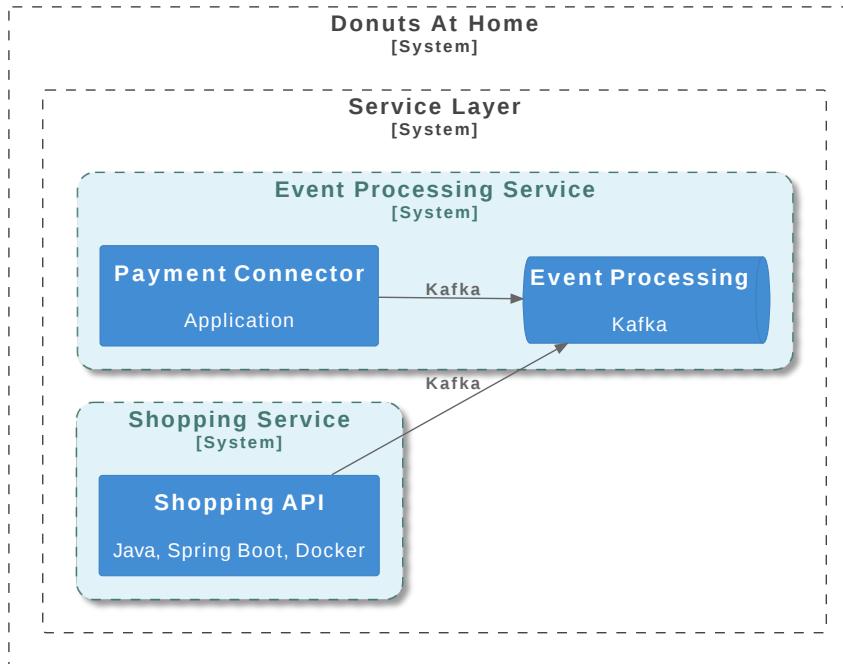
- Bus de message/Queue
- Producteurs
- Consommateurs

Exemples

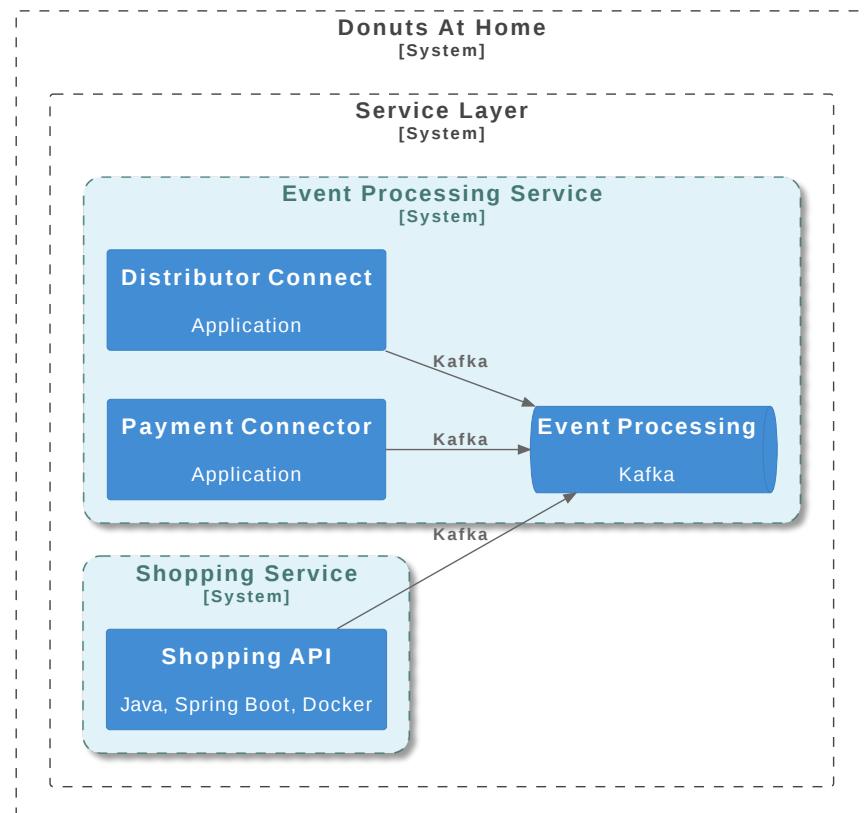
Kafka, Artemis, RabbitMQ

Modèles de communication

Point-à-Point



Publish/Subscribe (Pub/Sub)



Avantages

- Scalabilité améliorée
- Augmente la résilience des plateformes microservices
- Traitement au fil de l'eau des événements

Inconvénients

- La consistence des données est compliquée à mettre en oeuvre
- La gestion des erreurs est plus compliquée
- Il faut superviser le système de messagerie et gérer les cas où la file d'attente est saturée

Transactions distribuées

Rappels : ACID

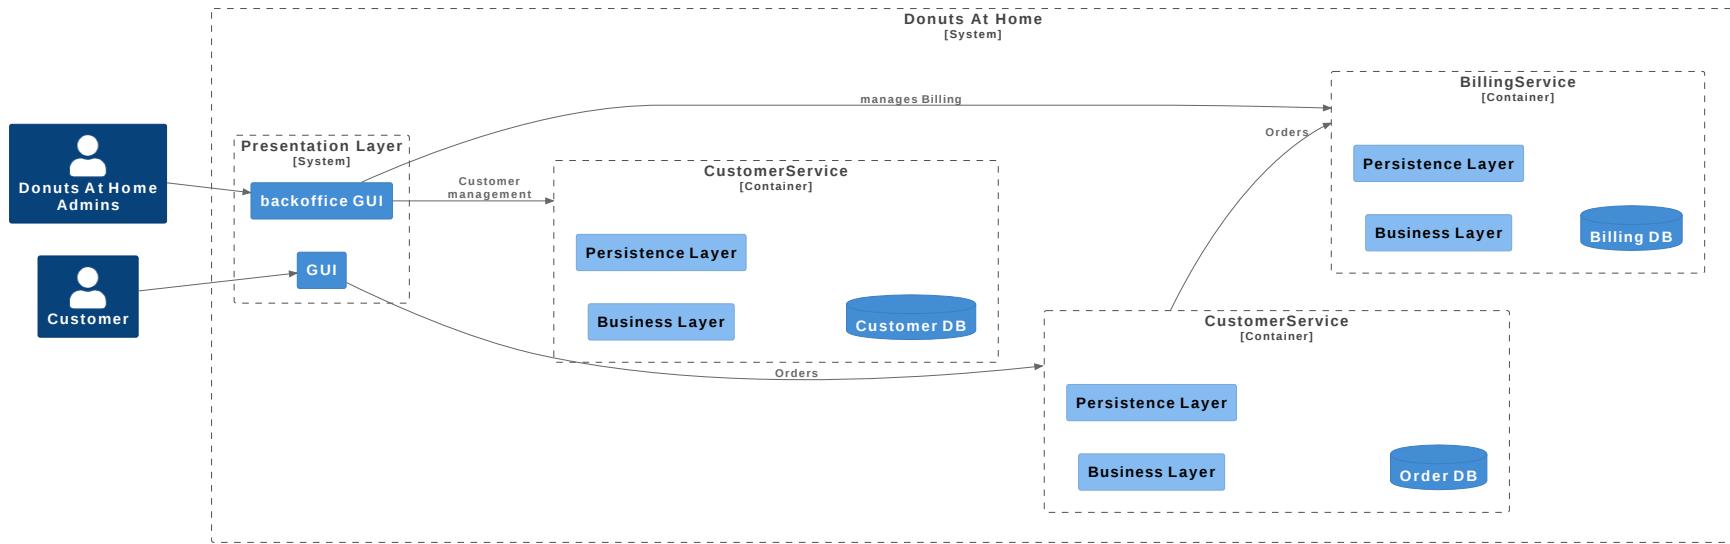
Les propriétés ACID se prêtent bien aux monolithes:

- Atomicité
- Cohérence
- Isolation
- Durabilité

Source: Wikipedia (1)

Comment faire dans une architecture distribuée ?

Exemple



Si dans l'appel à `BillingService` échoue:

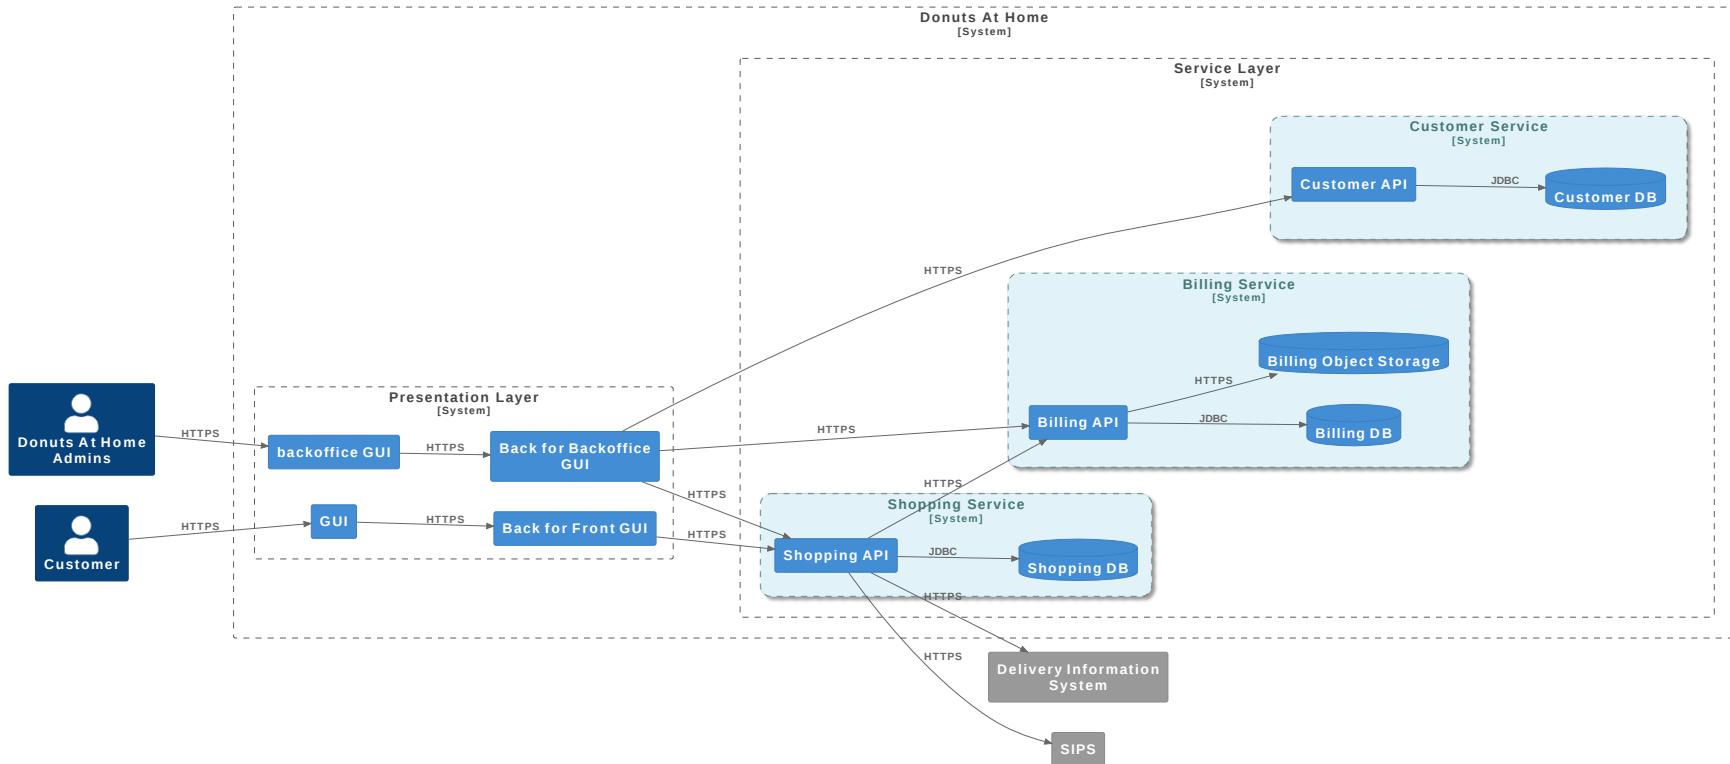
- Comment traiter les erreurs et garantir la cohérence des données dans `CustomerService` ?
- Comment piloter une transaction de bout en bout ?

Les Long Running Actions

Définition

Les "long running actions" dans le contexte des microservices sont des opérations qui durent longtemps, souvent beaucoup plus que la durée typique d'une requête HTTP. Ces opérations prolongées peuvent inclure des traitements complexes, des calculs intensifs, la génération de rapports, l'intégration avec des systèmes externes, la migration de données, etc. Gérer ces actions efficacement est crucial pour maintenir la performance, la scalabilité et la résilience de l'ensemble du système de microservices.

Exemple



Caractéristiques

Durée prolongée

Complexité

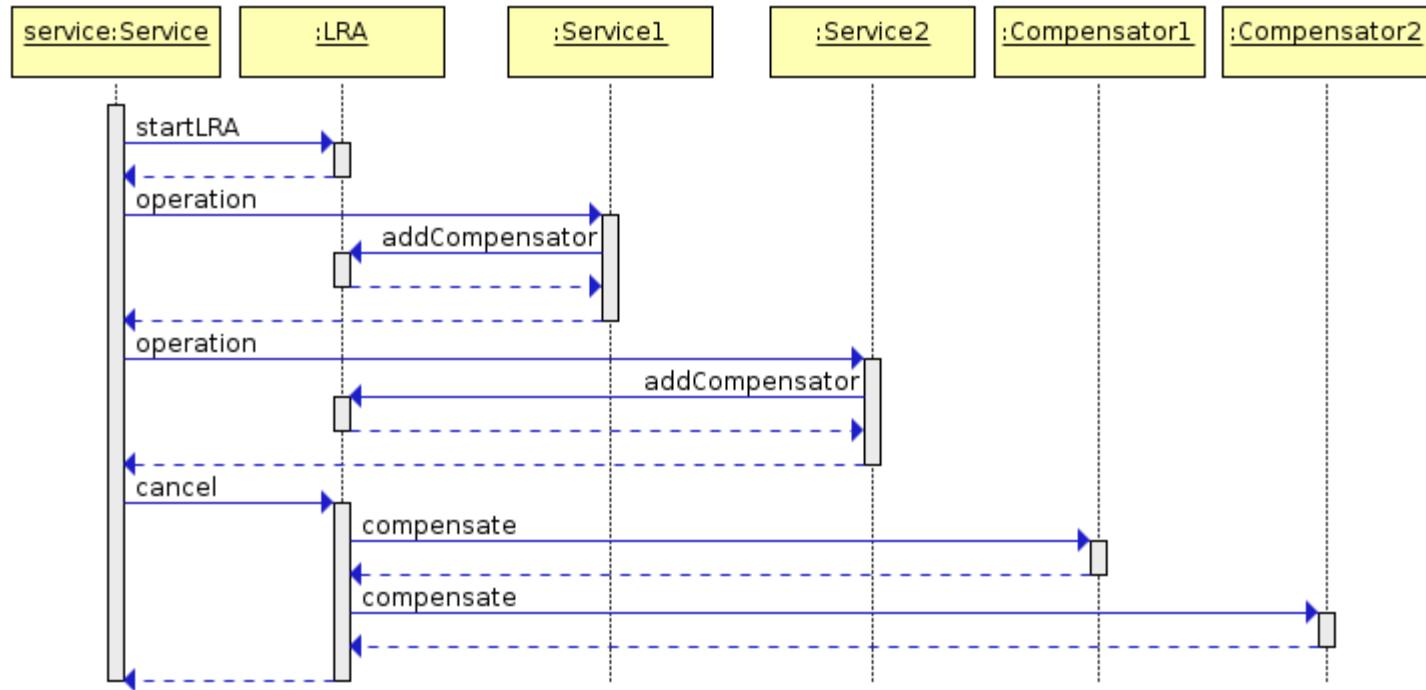
État Intermédiaire

Scalabilité

Tolérance aux Erreurs

Les Long Running Actions en Java

Modèle



- Article présentant les LRA

Le pattern SAGA

L'observabilité

L'observabilité est la capacité à comprendre l'état interne d'un système complexe. Lorsqu'un système est observable, un utilisateur peut identifier la cause première d'un problème de performance en examinant les données qu'il produit, sans tests ou codage supplémentaires. C'est l'un des moyens par lesquels les problèmes de qualité de service peuvent être abordés.

Logs, Traces et Monitoring

Les logs

Les logs (ou traces applicatives) sont des enregistrements chronologiques d'événements survenus dans une application ou un système.

Ils servent à fournir des informations détaillées sur les actions exécutées, les erreurs rencontrées et l'état du système à différents moments.

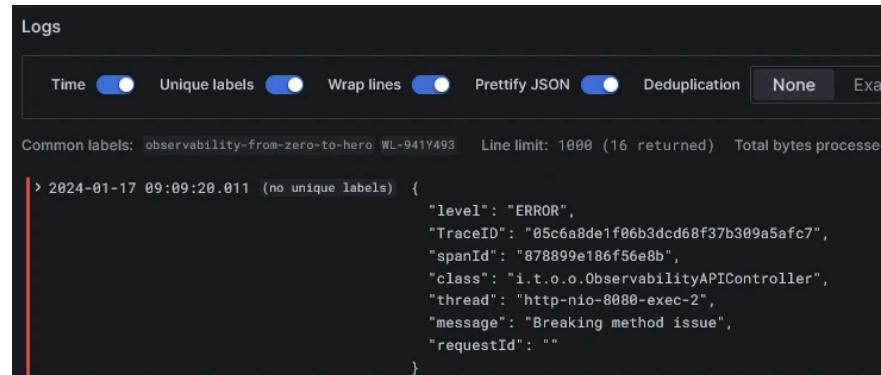
Quel log est utile ?

```
System.out.println("Je suis ici...");
```

ou

```
LOG.warn("Check card expiry date does not pass: bad format: {
```

Un exemple de log dans un format structuré:



The screenshot shows a log viewer with the following interface elements:

- Logs**: The main title.
- Filters/Controls**: A row of toggle switches for "Time", "Unique labels", "Wrap lines", "Prettify JSON", "Deduplication", and a dropdown menu set to "None".
- Log Summary**: Text indicating "Common labels: observability-from-zero-to-hero WL-941Y493 Line limit: 1000 (16 returned) Total bytes processed".
- Log Content**: A JSON object representing a log entry:

```
> 2024-01-17 09:09:20.011 (no unique labels) {
    "level": "ERROR",
    "TraceID": "05c6a8de1f06b3dc68f37b309a5afc7",
    "spanId": "878899e186f56e8b",
    "class": "i.t.o.o.ObservabilityAPIController",
    "thread": "http-nio-8080-exec-2",
    "message": "Breaking method issue",
    "requestId": ""
}
```

A vertical red bar highlights the timestamp "2024-01-17 09:09:20.011".

Principes clés

- Distinguer les logs de développement (utilisés pour le débogage) des logs de production.
- Utiliser les niveaux de log appropriés (DEBUG , INFO , WARN , ERROR , etc.).
- Fournir des messages clairs et utiles pour les OPS.
- Inclure le contexte métier pertinent (par exemple, l'échec de la création du contrat 123456).
- Assurer que les logs puissent être lus par un outil externe (comme un agrégateur de logs).
- Ne pas exposer de données sensibles dans les logs en respectant les normes de confidentialité telles que GDPR et PCI DSS.

Les agrégateurs de logs

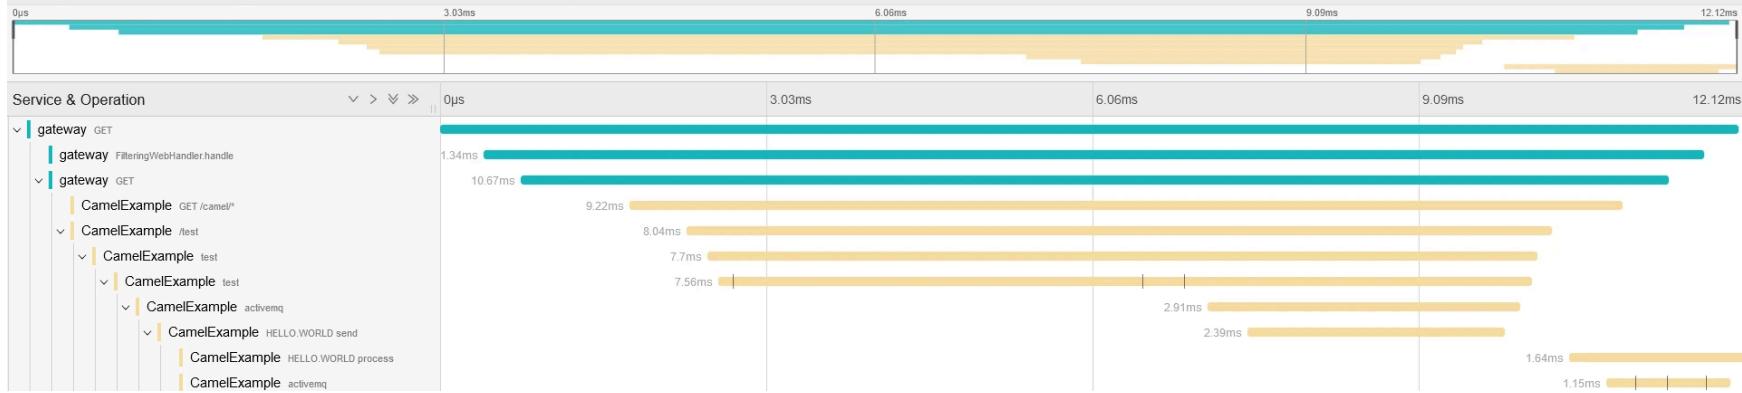
The screenshot shows the Google Cloud Logs Explorer interface. At the top, there's a navigation bar with 'Google Cloud' and a dropdown for the project 'fra-wlcp-product-dev'. A search bar is followed by a 'Search' button. The main area has tabs for 'Logs Explorer', 'Refine scope', and 'Project'. Below that, there are buttons for 'Query', 'Recent (17)', 'Saved (0)', 'Suggested (17)', and 'Library'. On the right, there are buttons for 'Share link', 'Learn', 'Clear query', 'Save', 'Stream logs', and 'Run query'. A 'Last 1 hour' button is also present. The main content area features a timeline from 'Sep 23, 3:09:30PM' to 'Sep 23, 4:10:00PM'. It displays a large number of log entries, with one entry highlighted in blue. The log fields sidebar lists services like 'wl-system', 'wlcp-product-demo', 'kube-system', etc., and resource types like 'Kubernetes Control Plane Components', 'Kubernetes Cluster', etc. The timeline shows a dense grid of colored dots representing log entries over time.

Les traces distribuées

1. Suivi des transactions de bout en bout
2. Corrélation des logs
3. Détection et isolation des problèmes
4. Contexte global
5. Optimisation de la Performance

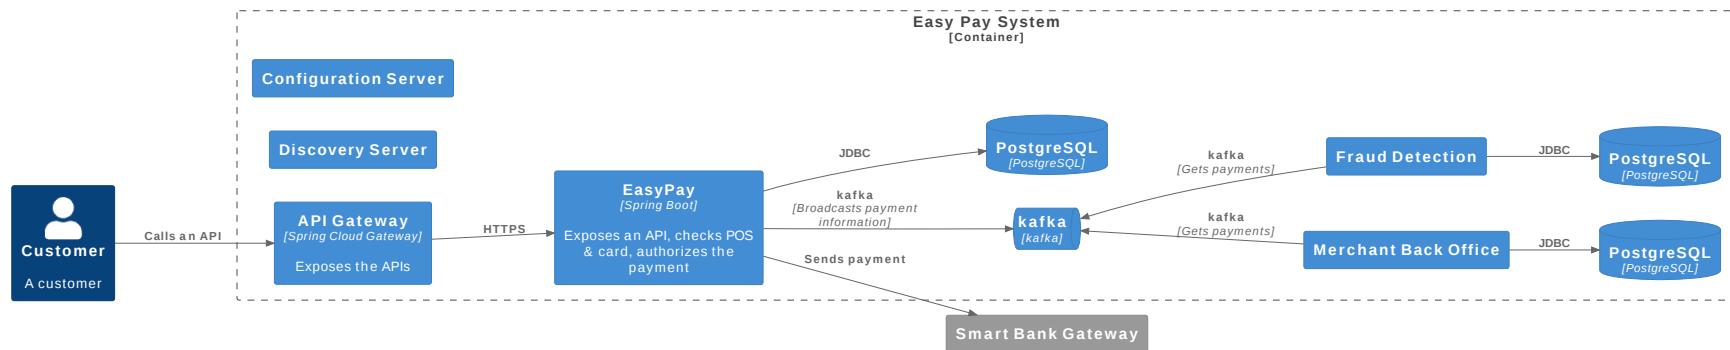
Attention aux performances!

Trace Start August 31 2023, 17:44:30.155 Duration 12.12ms Services 2 Depth 8 Total Spans 11



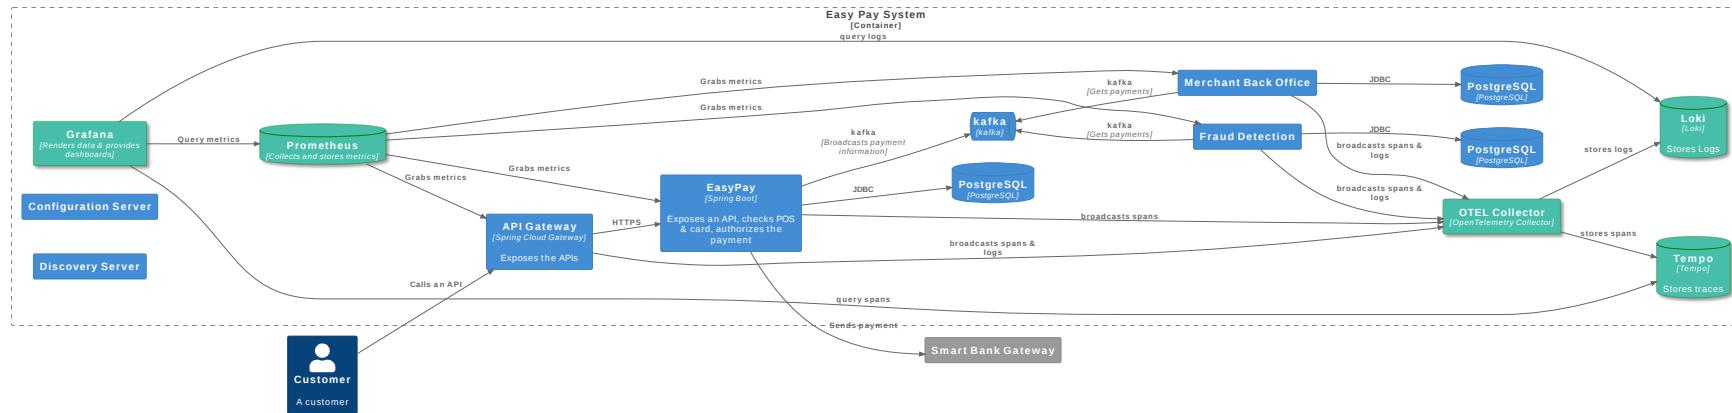
Un exemple d'implémentation

Une application de paiement basée sur des microservices

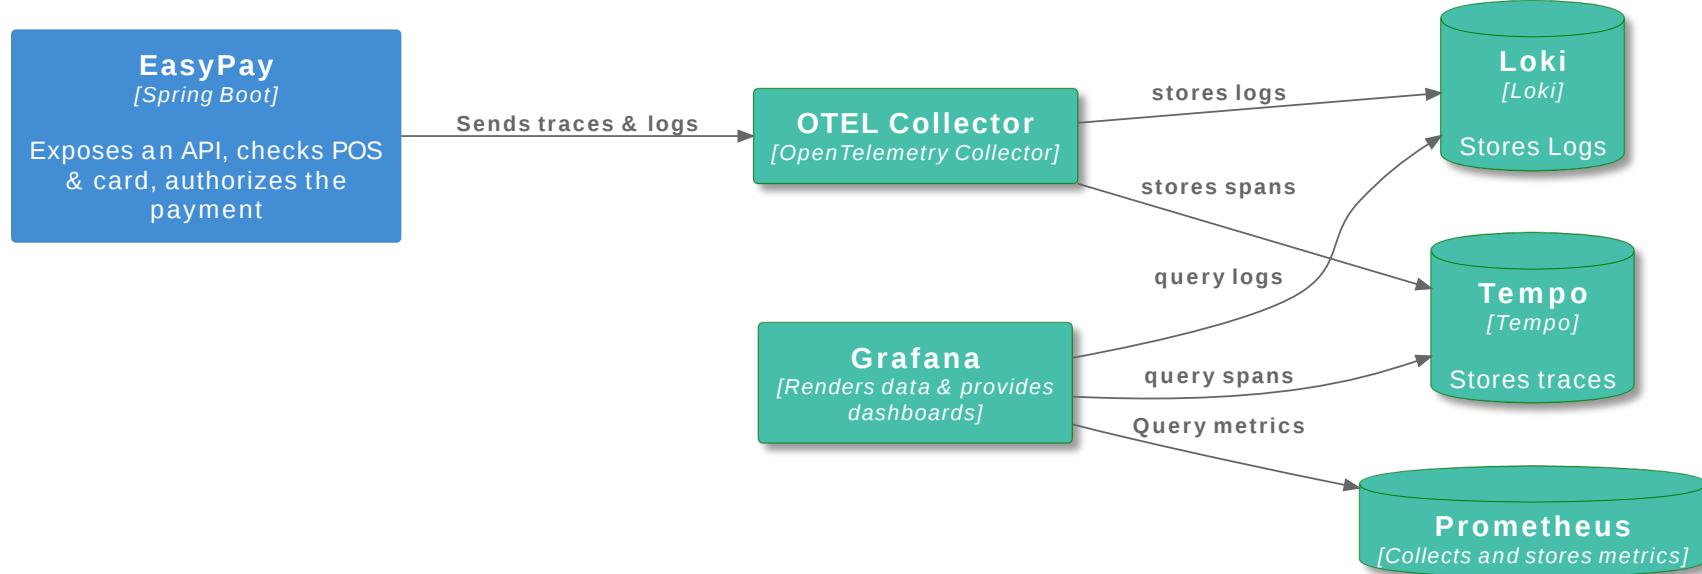


Utilisation de la plateforme Grafana

- Loki(3) va stocker les logs
- Tempo(4) va stocker les traces
- OTEL Collector(5) va collecter les logs et traces
- Grafana(6) va permettre l'affichage et la recherche



Zoom sur un service



Bibliography

- 1. Wikipedia. Propriétés ACID. Disponible sur:
https://fr.wikipedia.org/wiki/Propri%C3%A9t%C3%A9s_ACID (29)
- 2. Richardson C. Saga Pattern. Disponible sur: <https://microservices.io/patterns/data/saga.html> (34)
- 3. Grafana. Grafana Loki. Disponible sur: <https://grafana.com/oss/loki/> (43)
- 4. Grafana. Grafana Tempo. Disponible sur: <https://grafana.com/oss/loki/> (43)
- 5. OpenTelemetry. OpenTelemetry Collector. Disponible sur: <https://opentelemetry.io/> (43)
- 6. Grafana. Grafana Stack. Disponible sur: <https://grafana.com/about/grafana-stack/> (43)